

Doctorado en Procesos e Instituciones Políticas (DPIP)

Escuela de Gobierno · Universidad Adolfo Ibáñez

IX Simposio — Anatomía del presente: Tensiones sociales globales

24 de septiembre de 2026 · Sala Valparaíso, UAI, Santiago de Chile

Mesa 02 · Inteligencia artificial, lenguaje y esfera pública

Hablar como humano, corregir como máquina: tecnologías del tono y moralización del lenguaje en los LLM

Liz Zarate*, William Gómez

Universidad Central de Chile — Instituto Milenio ASOR

** Ponente principal; la afiliación indicada corresponde únicamente a la ponente.*

Resumen

Los modelos de lenguaje de gran escala (LLM) participan de manera creciente en actividades de escritura, conversación, asistencia y producción de contenidos. La investigación se ha concentrado en sus respuestas, los sesgos que reproducen, sus implicaciones éticas o el trabajo de quienes los entrenan. Mucho menos frecuente resulta el estudio de los documentos técnicos que orientan ese entrenamiento y establecen los criterios mediante los cuales los trabajadores evalúan las respuestas del modelo. Este trabajo analiza ese nivel del proceso de alineación a partir de cuatro guías utilizadas por anotadores y equipos de aseguramiento de calidad. El trabajo desplaza la atención desde los outputs hacia las infraestructuras documentales que organizan el entrenamiento,

El trabajo se sitúa en los estudios sociales de la ciencia y la tecnología y adopta el análisis crítico del discurso para reconstruir las reglas mediante las cuales estos documentos organizan la producción de lenguaje. El corpus incluye guías destinadas a la evaluación de prompts, clasificación de contenido sensible, comparación de respuestas textuales y valoración de voz sintética. El corpus fue obtenido mediante observación participante desarrollada por uno de los autores durante su trabajo como anotador y evaluador de calidad en plataformas de entrenamiento de inteligencia artificial.

El análisis identifica un régimen normativo articulado alrededor de la tríada Helpful, Honesty y Harmlessness (HHH), propuesta por Askell y el equipo de Anthropic como criterio de alineación para asistentes conversacionales. Las guías traducen esos principios en instrucciones que regulan la selección léxica, la modalidad verbal, el tratamiento de la incertidumbre, la administración del rechazo, las expresiones de empatía y los límites del contenido aceptable. Harmlessness ocupa un lugar predominante porque organiza taxonomías de daño y procedimientos para responder a situaciones sensibles. Helpfulness establece criterios de cooperación y relevancia, mientras Honesty regula la precisión factual, el reconocimiento de incertidumbre y las restricciones sobre la expresión de opiniones o experiencias atribuidas al modelo. Las instrucciones también regulan claridad, brevedad, cortesía, neutralidad afectiva y adecuación intercultural. En la evaluación de voz sintética aparecen criterios dirigidos a producir naturalidad, expresividad, ritmo, respiración y un acento con escasas marcas perceptibles de artificialidad.

La humanidad atribuida al modelo emerge así de un conjunto de operaciones distribuidas entre ingenieros, plataformas, anotadores y evaluadores, quienes estabilizan criterios compartidos sobre formas de interacción aceptables.

Palabras clave: *LLM; alineación de IA; análisis crítico del discurso; estudios sociales de la ciencia y la tecnología; guías de entrenamiento*

Sobre la ponente principal *

Liz Zárate Luengas. Antropóloga, magíster en Sociología. Candidata a doctora en el Doctorado en Estudios Sociales Avanzados de la Universidad Central de Chile y doctorante del Instituto Milenio sobre Autoridad y Regulación Social (ASOR), ANID/MILENIO/ICS2025_02. Santiago, Chile.